

BÀI TẬP CHƯƠNG 3 – DATA PREPROCESSING

Dataset: Iris Dataset

Mục tiêu: Hiểu dữ liệu và thực hành Data Preprocessing theo ba nhóm nội dung: Understanding Data; Dimensionality Reduction (Feature Selection, Feature Extraction); Data Normalization.

Phần	Nội dung	Yêu cầu thực hiện	Kết quả cần đạt
1. Understanding Data	1.1. Dữ liệu được yêu cầu thực hiện	Tải bộ dữ liệu Iris từ trang UCI. Xác định số lượng samples, số lượng features, số classes, tên feature, ý nghĩa và đơn vị của từng feature.	Bảng mô tả cấu trúc bộ dữ liệu.
	1.2. Data type và Attribute type	Xác định data type và attribute type của từng thuộc tính trong bộ dữ liệu.	Bảng phân loại kiểu dữ liệu và kiểu thuộc tính.
	1.3. Biểu diễn dữ liệu	Xác định sample, feature và label. Biểu diễn dữ liệu dưới dạng ma trận X và vector nhãn y.	Xây dựng được bảng training set theo dạng các record (x, y), trong đó x gồm các feature set và y là class label.
	1.4. Thống kê dữ liệu	Tính Min, Max, Mean và Standard Deviation cho từng feature.	Bảng thống kê và nhận xét về range và mức độ phân tán của các feature.
	1.5 Feature correlation	Tính Pearson correlation coefficient giữa từng cặp numerical features. Vẽ scatter plot cho các cặp feature và đối chiếu với giá trị correlation coefficient.	Bảng hệ số tương quan giữa các feature; các scatter plots; nhận xét về chiều và mức độ tương quan, đồng thời xác định các cặp feature có khả năng chứa thông tin dư thừa.
2. Dimensionality Reduction – Feature Selection	2.1. Feature Selection bằng 2D Visualization	Tạo tất cả các cặp feature từ 4 feature ban đầu. Vẽ scatter plot 2D cho từng cặp. Phân biệt các class bằng màu hoặc marker.	Bộ scatter plots 2D; lựa chọn và xếp hạng các cặp feature dựa trên khả năng biểu diễn dữ liệu.
	2.2. Feature Selection bằng 3D Visualization	Tạo tất cả các tổ hợp gồm 3 feature. Vẽ scatter plot 3D cho từng tổ hợp.	Bộ scatter plots 3D; lựa chọn tổ hợp feature phù hợp và nhận xét so sánh với biểu diễn 2D.
	2.3. Feature Selection bằng Fisher Ratio	Tính Fisher Ratio/Fisher Score cho từng feature. Sắp xếp các feature theo giá trị Fisher Score và biểu diễn bằng bar chart.	Bảng Fisher Score, biểu đồ xếp hạng và tập feature được lựa chọn.
	2.4. Đối chiếu các phương pháp Feature Selection	So sánh kết quả lựa chọn feature từ visualization và Fisher Ratio.	Nhận xét về sự tương đồng hoặc khác biệt giữa các phương pháp và kết luận về feature được lựa chọn.
3. Dimensionality Reduction – Feature Extraction	3.1. PCA	Sử dụng toàn bộ feature ban đầu. Standardize dữ liệu và thực hiện PCA để chuyển dữ liệu sang không gian có số chiều thấp hơn.	Principal Components, Explained Variance Ratio và Cumulative Explained Variance.
	3.2. Lựa chọn số chiều sau PCA	Phân tích lượng thông tin giữ lại theo số Principal Components, đặt yêu cầu với energy là 95%	Biểu đồ cumulative explained variance và số chiều được lựa chọn sau PCA.
	3.3. PCA Visualization	Giảm dữ liệu về 2 dimensions và vẽ scatter plot PC1–PC2.	Scatter plot trong không gian PCA và nhận xét về biểu diễn dữ liệu sau Feature Extraction.
	3.4. Feature Selection vs. Feature Extraction	So sánh dữ liệu thu được từ Feature Selection và PCA. Minh họa hai quá trình d→k.	Sơ đồ hoặc bảng so sánh hai phương pháp và kết luận ngắn.

Phần	Nội dung	Yêu cầu thực hiện	Kết quả cần đạt
4. Data Normalization	4.1. Min-Max Normalization	Thực hiện Min-Max normalization cho tất cả các numerical features về khoảng $[0, 1]$. Chọn 2 features để vẽ scatter plot dữ liệu trước và sau normalization.	Bảng giá trị Min, Max trước và sau normalization; scatter plot trước-sau và nhận xét sự thay đổi của dữ liệu.
	4.2. Z-score Standardization	Thực hiện Z-score normalization cho toàn bộ các numerical features. Sử dụng cùng cặp 2 features đã chọn ở phần Feature Selection để vẽ scatter plot dữ liệu trước và sau normalization.	Bảng Mean và Standard Deviation trước và sau normalization; scatter plot trước-sau và nhận xét sự thay đổi của dữ liệu.
	4.3. So sánh hai phương pháp chuẩn hóa	So sánh Original Data, Min-Max Normalization và Z-score Normalization theo các thông số Min, Max, Mean và Standard Deviation. Sử dụng cùng cặp 2 features đã chọn để trực quan hóa và đối chiếu dữ liệu giữa ba trường hợp.	Bảng so sánh các thông số thống kê; hình trực quan của ba trường hợp và nhận xét về sự khác nhau giữa hai phương pháp chuẩn hóa.

Yêu cầu trình bày và nộp bài

- Sinh viên trình bày báo cáo bằng slide, đúng thứ tự và đầy đủ các nội dung trong bảng yêu cầu.
- Với mỗi nội dung có công thức, cần trình bày:
Công thức $\rightarrow$ Ví dụ tính thủ công $\rightarrow$ Kết quả bằng code $\rightarrow$ Đối chiếu và nhận xét.
- Các kết quả xử lý dữ liệu phải được thể hiện rõ bằng bảng, số liệu và hình trực quan.
- Các biểu đồ phải có đầy đủ tên trục, legend, title/caption và thể hiện rõ các class khi có liên quan.